Manual de Utilização — Engineering Model Router V1

21 de setembro de 2026

Contents

Manual de Utilização — Engineering Model Router V1 **1**
1. Pré-requisito: configurar credenciais de IA 1
2. Onde o Router aparece no menu 3
3. Criando uma Engineering Task 3
4. Rodando a task 5
5. Lendo o resultado 6
6. Consultando os modelos disponíveis 8
7. Overview e Release Closure 9
8. Cancelando uma task 9
9. Referência rápida de API 9

Manual de Utilização — Engineering Model Router V1

Guia prático, com capturas de tela reais e exemplos realistas, de como configurar e operar o Engineering Model Router V1. Todas as imagens deste manual foram capturadas de uma execução real da plataforma — nenhuma é mockup: as chamadas de IA, os testes e as decisões de roteamento aconteceram de verdade contra provedores externos reais.

Para a arquitetura interna, ver `ENGINEERING_MODEL_ROUTER_ARCHITECTURE.md`. Para o modelo de segurança, ver `ENGINEERING_MODEL_ROUTER_SECURITY.md`. Este documento é só o "como usar".

1. Pré-requisito: configurar credenciais de IA

O Router reutiliza a tela de configuração de IA que já existe no RAP (`/config?tab=ai`) — não há uma tela de credenciais separada para o Router. Um usuário `super_admin` pode configurar credenciais em nome de qualquer tenant acrescentando `?tenant=<id>` à URL; o Router usa por padrão o tenant interno `system` (configurável via `ENGINEERING_ROUTER_TENANT_ID`, ver `ENGINEERING_MODEL_ROUTER_OPERATIONS.md`).

Acesse **`/config?tenant=system&tab=ai`**:

Selecione o provider, cole a API key real no campo, clique em **Testar API Key** (isso faz uma chamada real e barata ao provedor — nunca aceite uma credencial sem testar) e só depois em **Salvar Credenciais**:

Repita para cada provider que quiser habilitar. O resumo no topo da aba mostra quantos providers têm chave configurada para aquele tenant:

Atenção real observada em produção: "chave configurada" não significa "conta com saldo". Ao rodar o pilot desta missão, duas credenciais pré-existentes (Anthropic, DeepSeek) estavam sintaticamente válidas mas sem crédito na conta do provedor — o Router corretamente reportou `PROVIDER_UNAVAILABLE` em vez de fingir sucesso (ver §5). Recomenda-se testar periodicamente e remover/atualizar credenciais que passem a falhar.

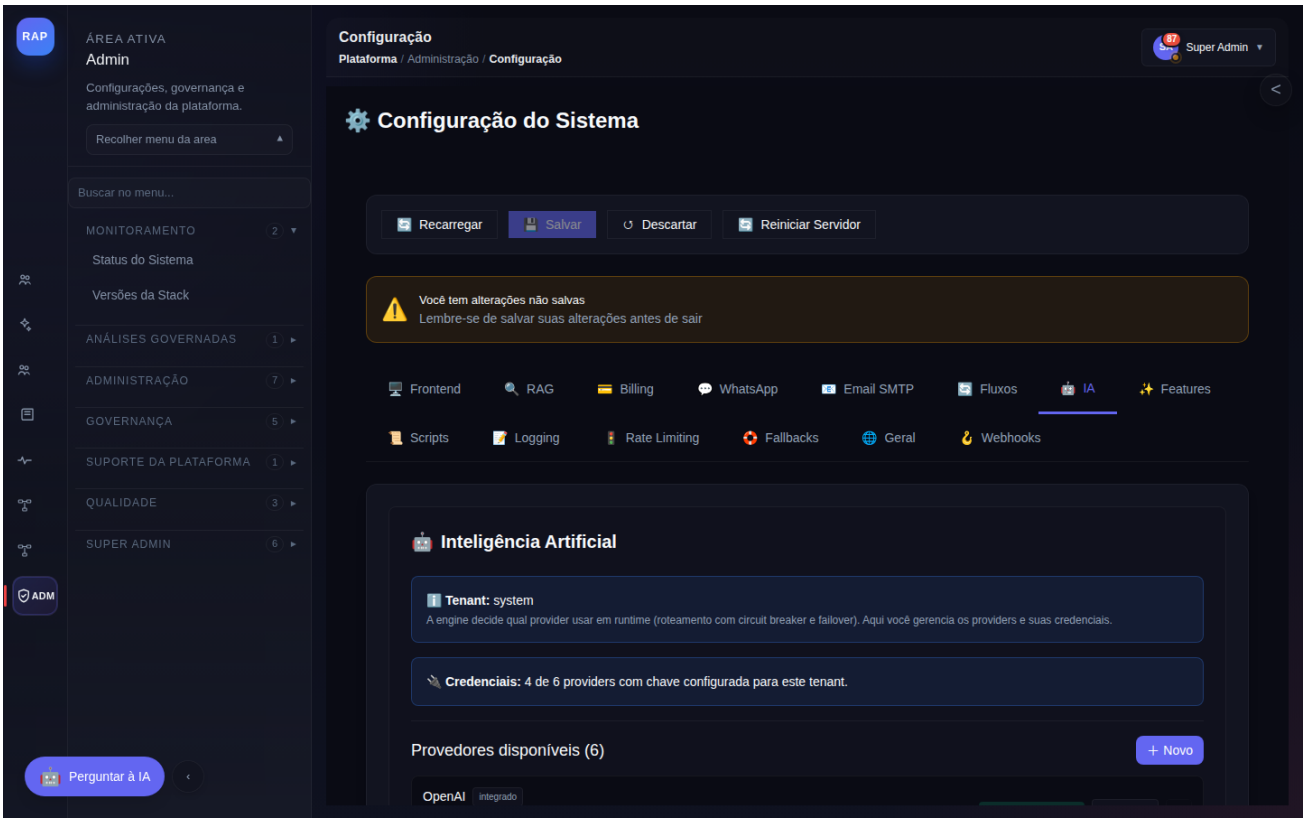


Figure 1: Tela de configuração de IA, tenant system, lista de providers

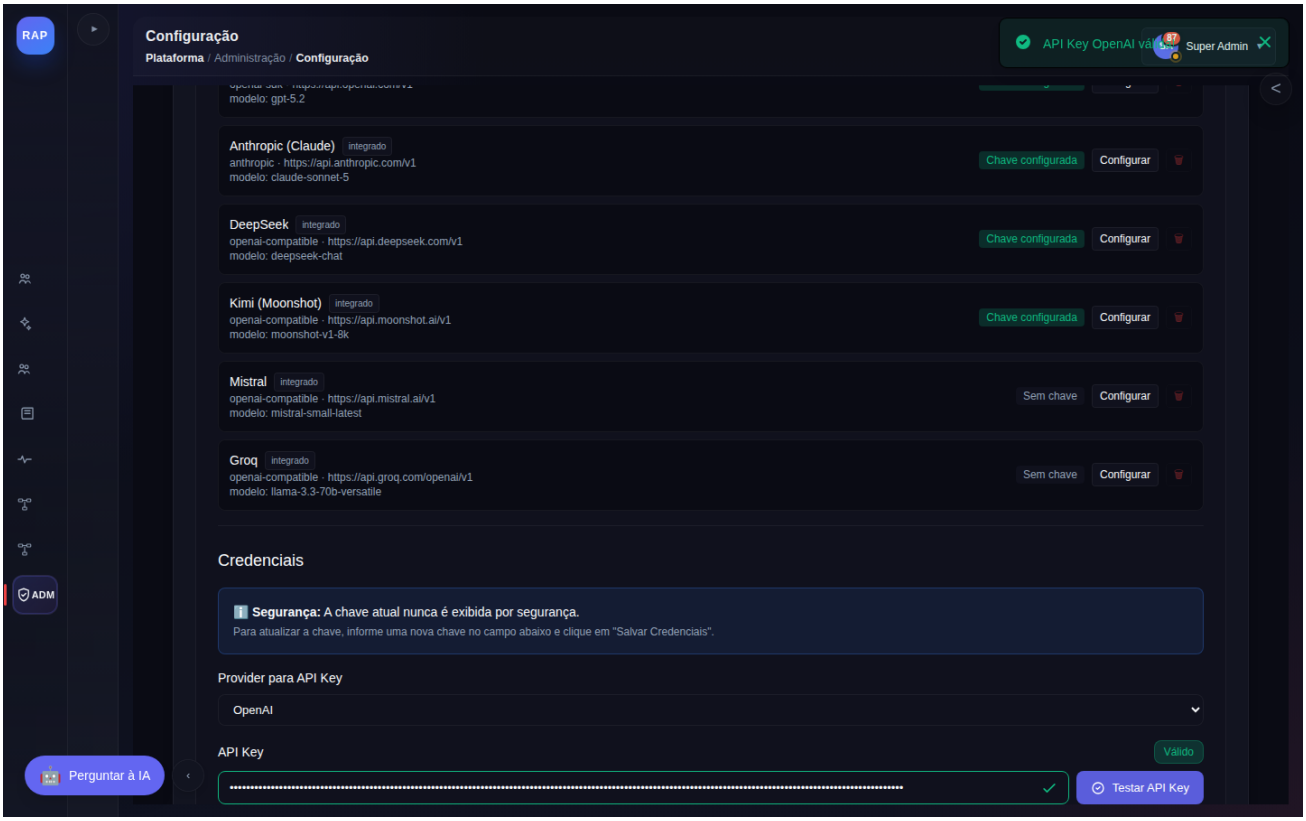


Figure 2: Teste real da chave OpenAI — resultado “Válido”

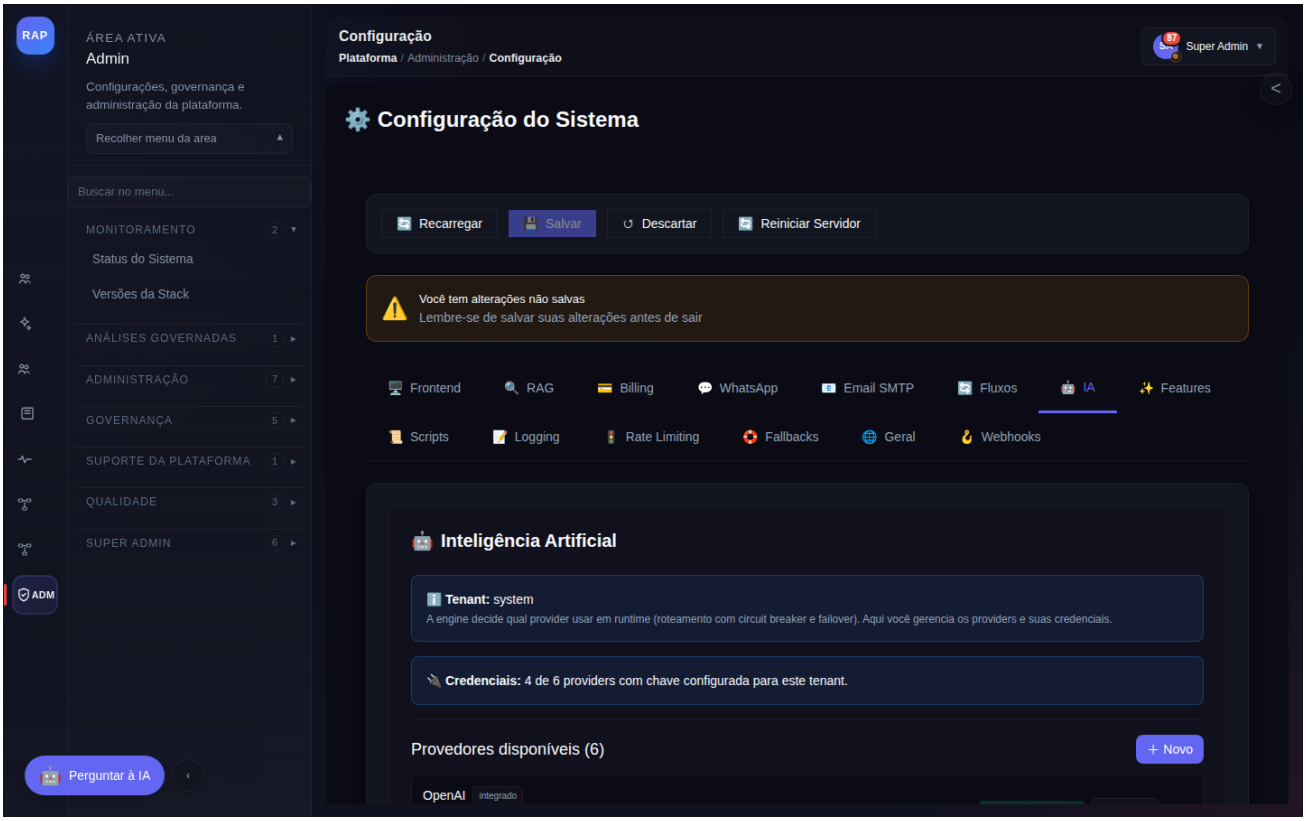


Figure 3: Resumo: 4 de 6 providers com chave configurada

2. Onde o Router aparece no menu

Menu lateral → **Central Dev** → **Engineering**, com quatro sub-itens: Overview, Tasks, Models/Router, Release Closure (a quinta tela, Task Detail, é acessada a partir de Tasks). Toda a área é DEVELOPMENT-only — um usuário classificado como PRODUCTION não vê o menu e, mesmo acessando a URL diretamente, recebe 403 `classification_required` do backend.

3. Criando uma Engineering Task

Vá em **Tasks** e clique em **+ Nova Task**. Preencha:

- **Título**: curto, descritivo.
- **Objetivo**: quanto mais preciso, melhor — o CODER só vê o que estiver no contexto (arquivos dentro de `allowedPaths` + o texto do objetivo). Se a tarefa depende de um módulo que o CODER não vai poder editar (só ler/entender), descreva seu comportamento exato no objetivo.
- **taskType/risk**: pode deixar em "auto" — o classifier determinístico infere a partir do objetivo e dos `allowedPaths` (ex.: um caminho em `scripts/governance/` vira GOVERNANCE automaticamente). Se preencher, o valor explícito nunca é sobrescrito.
- **allowedPaths**: um caminho (ou glob) por linha — é o único lugar onde o patch pode escrever. Qualquer tentativa de tocar outro arquivo é rejeitada antes de aplicar (PATCH_OUTSIDE_ALLOWED_SCOPE).
- **testCommands**: um comando por linha — a autoridade de PASS/FAIL. Precisa estar na allowlist (`npm test`, `npm run test:*`, `npx jest ...`, `node scripts/...`, `git status/diff`).

Exemplo real usado no pilot desta missão:

```
Título:      Adicionar teste unitário para typeCompatibility.js
```

```
Objetivo:   O módulo engine/utils/typeCompatibility.js exporta (CommonJS) um único objeto:
            module.exports = { TYPE_COMPATIBILITY }. TYPE_COMPATIBILITY é um
          Record<string,string[]> — a chave é o tipo do nó de origem e o valor é a lista de
          tipos de nó que podem ser destino. Não possui teste unitário dedicado. Crie o
              arquivo tests/unit/typeCompatibilityRules.test.js (require relativo:
              "../../engine/utils/typeCompatibility") cobrindo pelo menos:
              (1) TYPE_COMPATIBILITY.merge NÃO contém "merge" na sua lista;
              (2) TYPE_COMPATIBILITY.start contém "message";
              (3) TYPE_COMPATIBILITY.end é um array vazio.
taskType:     TEST_GENERATION (auto)
risk:         LOW (auto)
allowedPaths:   tests/unit/typeCompatibilityRules.test.js
testCommands:  npx jest --testPathPattern=tests/unit/typeCompatibilityRules.test.js -
--no-coverage
```

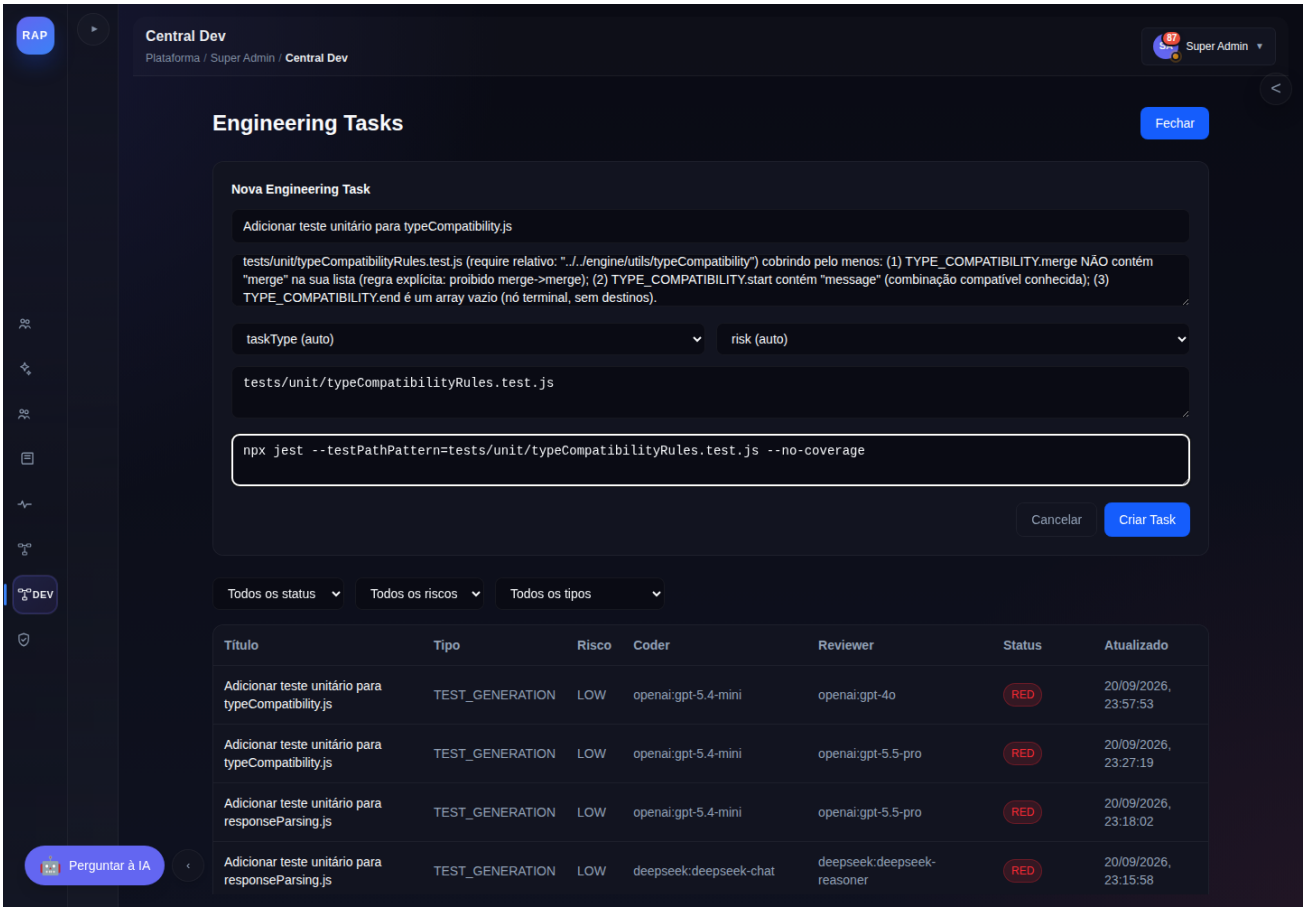


Figure 4: Formulário de nova task preenchido, com a lista de tasks anteriores abaixo

A lista de tasks embaixo do formulário já mostra, para cada uma, o CODER e o REVIEWER realmente selecionados e o status — inclusive o histórico real de tentativas RED desta mesma missão antes de chegar a GREEN (ver §5, é honesto por design: nada é escondido).

Via API (equivalente ao formulário):

```bash
curl -X POST http://localhost:3001/engineering/tasks \
  -H "Authorization: Bearer $TOKEN" \
  -H "Content-Type: application/json" \
  -d '{
    "title": "Adicionar teste unitário para typeCompatibility.js",
```

```
    "objective": "...",
    "taskType": "TEST_GENERATION",
    "risk": "LOW",
    "allowedPaths": ["tests/unit/typeCompatibilityRules.test.js"],
    "testCommands": ["npx jest
↪   --testPathPattern=tests/unit/typeCompatibilityRules.test.js --no-coverage"],
    "maxIterations": 3
  }'
```

Ao criar, a task já vem classificada (estado `CLASSIFIED`):

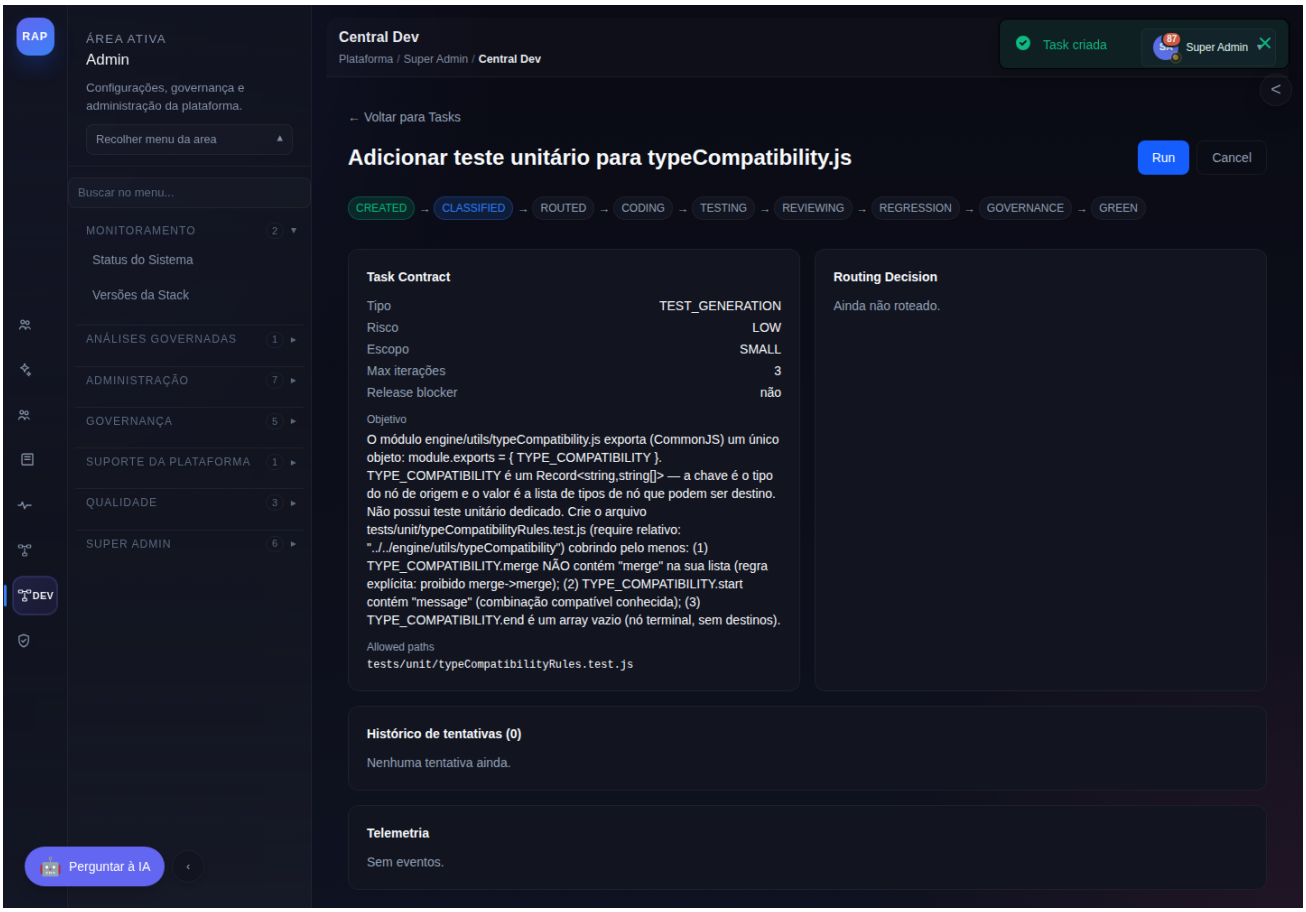


Figure 5: Task recém-criada: contrato, ainda sem roteamento

4. Rodando a task

Na Task Detail, clique em **Run** (ou `POST /engineering/tasks/:id/run`). A resposta é imediata (`202 Accepted`, fire-and-forget) — o processamento real (chamadas de LLM, aplicação de patch, execução de teste) roda em segundo plano. Acompanhe recarregando a página ou fazendo polling em `GET /engineering/tasks/:id`.

```
curl -X POST http://localhost:3001/engineering/tasks/<id>/run -H "Authorization:
↪  Bearer $TOKEN"
# {"taskId":"...","status":"ACCEPTED"}
```

5. Lendo o resultado

Quando termina, a Task Detail mostra a trilha completa do pipeline, a decisão de roteamento real (com `reasonCodes` estruturados, nunca texto do modelo), o patch gerado, o resultado do teste determinístico e a decisão do reviewer:

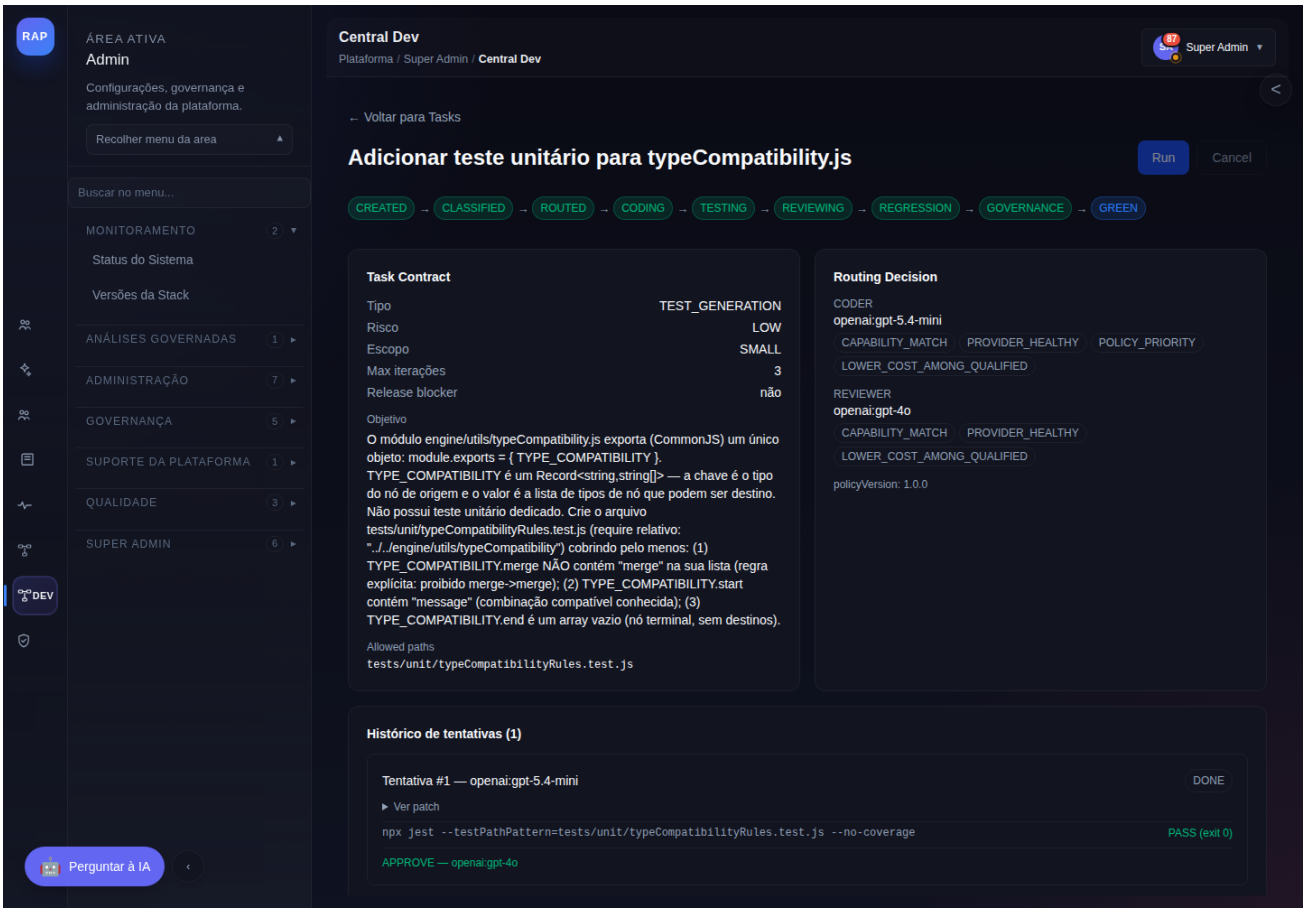


Figure 6: Task GREEN: pipeline completo, routing decision, teste PASS, review APPROVE

Neste exemplo real: o CODER (`openai:gpt-5.4-mini`, mais barato entre os qualificados) gerou o patch; `TESTING` rodou `npx jest ... --testPathPattern=tests/unit/typeCompatibilityRules.test.js` de verdade dentro de um workspace isolado (`git worktree`) e obteve `exit code 0`; o REVIEWER (`openai:gpt-4o` — um modelo diferente do coder, escolhido porque é o único outro qualificado com a capability `CODE_REVIEW`) aprovou sem findings. O patch pode ser expandido:

O arquivo de teste gerado nunca tocou o repositório principal — ele existiu só dentro do workspace isolado durante a execução e foi descartado ao final (`git worktree remove`). Isso é intencional: o Router produz evidência de que um patch funciona, mas a integração ao branch principal segue o fluxo oficial do time, fora do escopo do Router V1.

O caminho real até o GREEN (histórico honesto de troubleshooting)

Esta mesma missão expõe, de propósito, o processo real de chegar a um GREEN — a lista de Tasks mostra várias tentativas anteriores em RED antes da que funcionou, cada uma com sua própria causa raiz real, todas registradas sem serem escondidas ou apagadas:

1. Um provider tinha credencial configurada mas **sem crédito na conta** — o Router reportou `PROVIDER_UNAVAILABLE` (mensagem real do provedor: *"Your credit balance is too low"*).

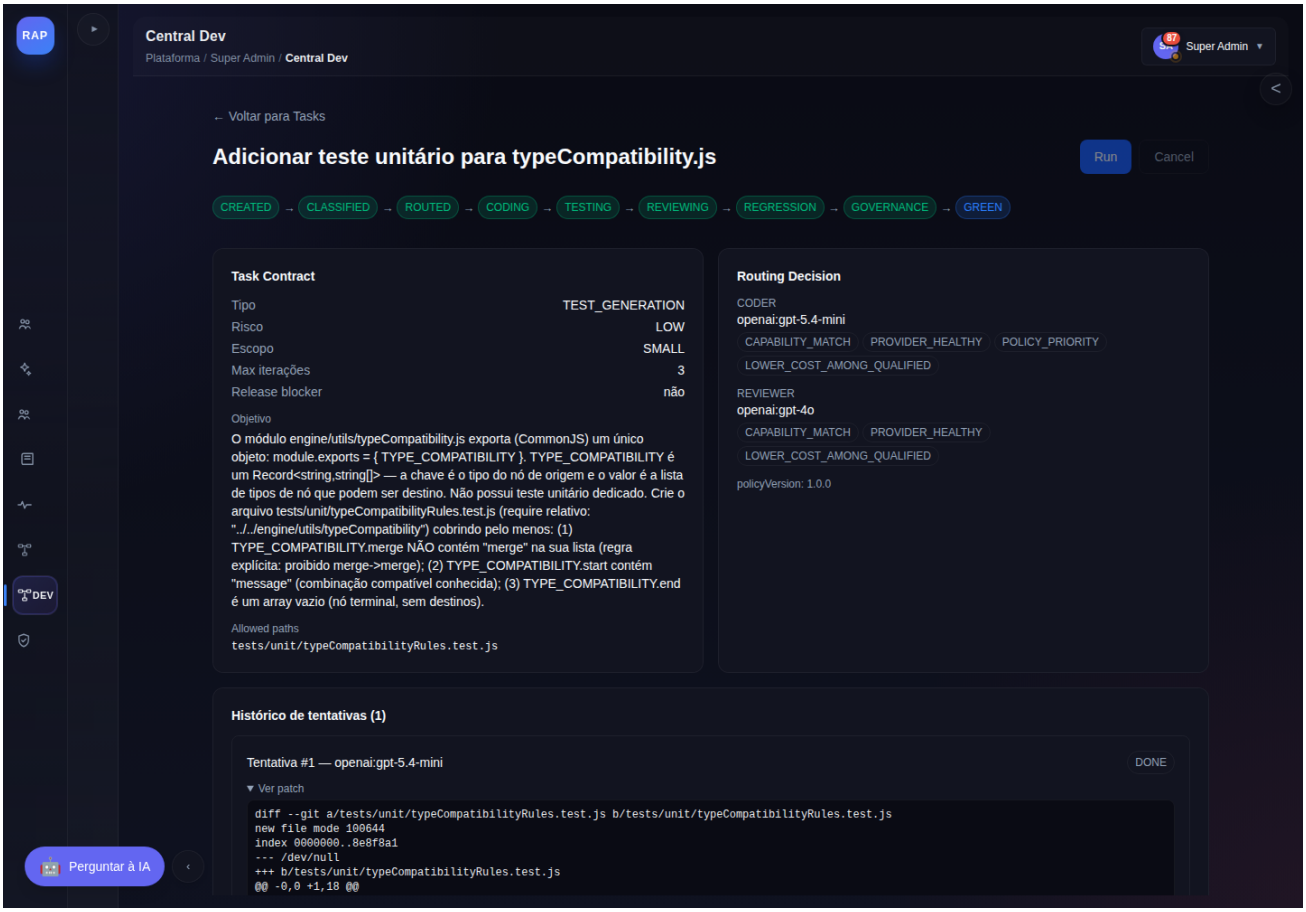


Figure 7: Patch real expandido — unified diff gerado pelo CODER

2. Um modelo mapeado no capability registry (`gpt-5.5-pro`) **não existia mais como modelo de chat real** na API — a chamada retornou `404`. Corrigido adicionando um modelo real confirmado (`gpt-4o`) como reviewer alternativo.
3. O CODER gerou uma resposta cujo `diff` continha, dentro do próprio código de teste, um exemplo de string JSON — o escaping de aspas internas quebrou o `JSON.parse` do envelope externo. Corrigido com um reparador de fallback (`repairCoderResponse`).
4. O CODER declarou 18 linhas no cabeçalho de um hunk mas só escreveu 16 — erro clássico de contagem de LLMs gerando diff — e `git apply` rejeitava o patch inteiro por isso, mesmo com o conteúdo perfeitamente correto. Corrigido recalculando a contagem real do hunk antes de aplicar (`hunkNormalizer.normalizeHunkHeaders`).

Nenhuma dessas falhas foi escondida ou contornada fingindo sucesso — cada uma ficou registrada como uma task RED real, com a causa exata em `last_error`/`error` de cada tentativa, e as robustezes que elas motivaram (itens 3 e 4) agora fazem parte do Router para qualquer task futura.

6. Consultando os modelos disponíveis

Em **Models / Router**, cada modelo mapeado mostra seu status real (nunca uma suposição):

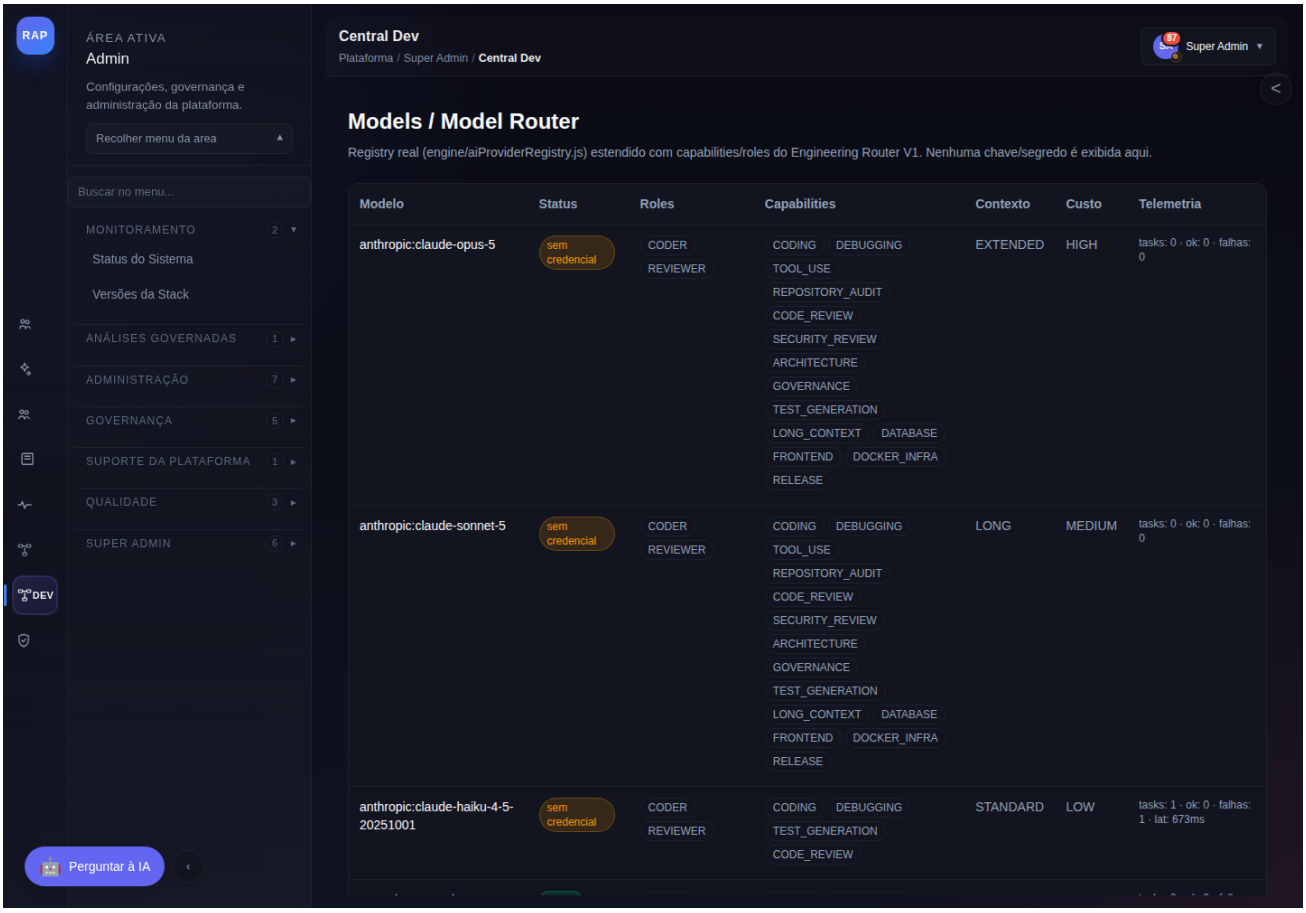


Figure 8: Tela de Models — status real por credencial/health, telemetria acumulada

`sem credencial` significa que não há chave salva para aquele provider neste tenant — é diferente de `unhealthy` (credencial existe, mas o circuit breaker abriu por falhas reais) e de `ready` (qualificado e saudável). A telemetria (`tasks`, `ok`, `falhas`, `lat`) é somada a partir de eventos reais — nunca projetada ou estimada.

7. Overview e Release Closure

Overview dá a visão consolidada (totais por status, tasks ativas):

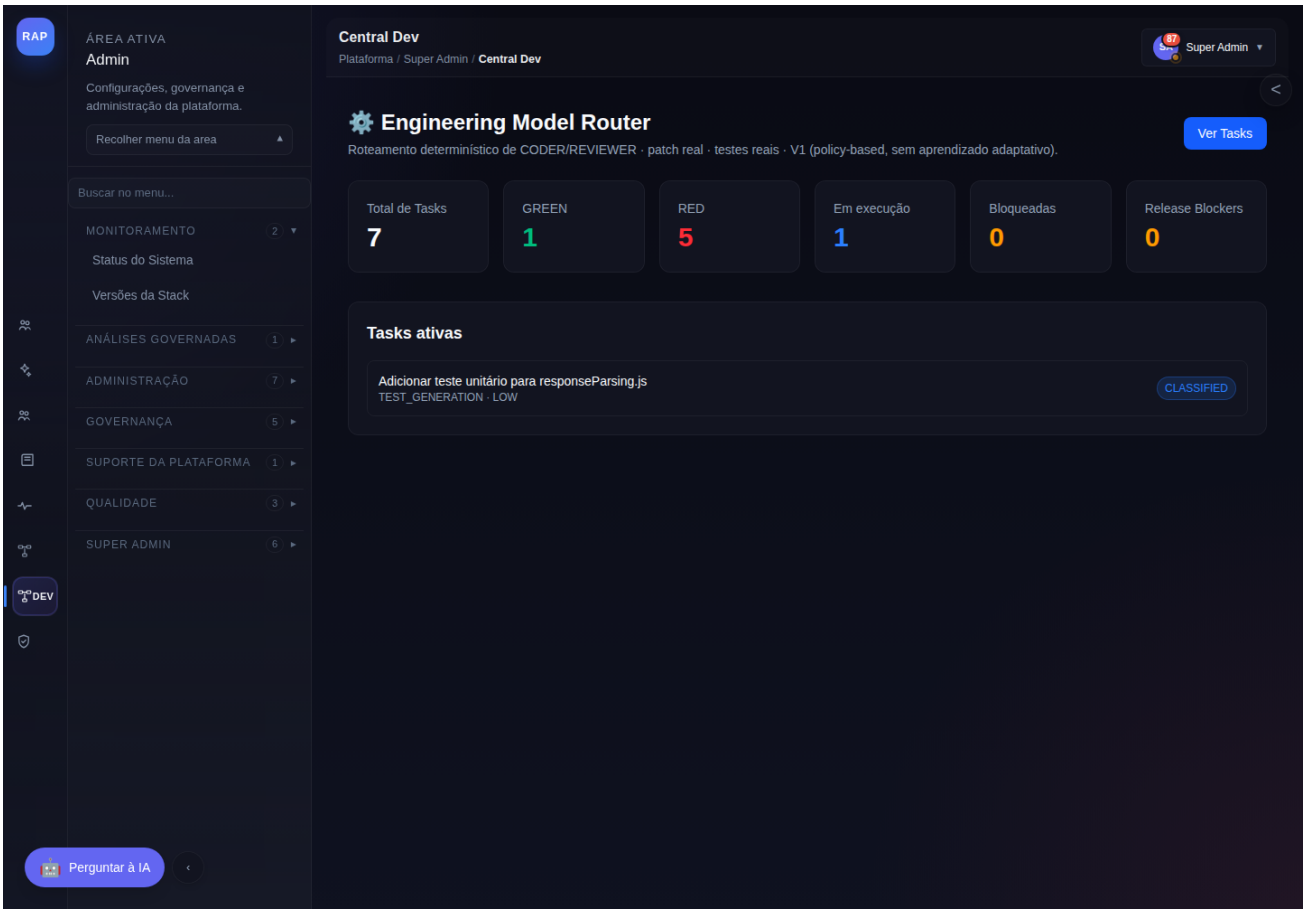


Figure 9: Overview: 7 tasks, 1 GREEN, 5 RED, release blockers 0

Release Closure cruza o estado do Engineering Router com os artefatos de governança reais do RAP (`governance/.current-run.json`, `qa-mesh/go-no-go-report.json`, `governance/final-readiness-report.json`) — nunca declara um release limpo se qualquer um desses artefatos faltar ou não indicar GO/PASS:

8. Cancelando uma task

Enquanto não estiver em estado terminal (`GREEN`/`RED`/`BLOCKED`/`CANCELLED`), qualquer task pode ser cancelada pelo botão **Cancel** ou `POST /engineering/tasks/:id/cancel`. Cancelar uma task que já está rodando (chamada de LLM em andamento) é seguro — o loop trata a transição de estado concorrente sem lançar exceção.

9. Referência rápida de API

Rota	Uso
`GET /engineering/overview`	Totais e tasks ativas
`GET /engineering/tasks`	Lista (filtros `status`, `risk`, `taskType`)
`POST /engineering/tasks`	Cria (classifica automaticamente)
`GET /engineering/tasks/:id`	Task Contract + routing decision + status

Rota	Uso
`POST /engineering/tasks/:id/run`	Dispara execução (202, fire-and-forget)
`POST /engineering/tasks/:id/cancel`	Cancela
`GET /engineering/tasks/:id/attempts`	Histórico de tentativas
`GET /engineering/tasks/:id/tests`	Resultados de teste por tentativa
`GET /engineering/tasks/:id/reviews`	Decisões do reviewer por tentativa
`GET /engineering/tasks/:id/telemetry`	Tokens/latência/custo por chamada
`GET /engineering/models`	Registry + status real + telemetria acumulada
`GET /engineering/router/decision/:taskId`	Classificação + routing decision isolados
`GET /engineering/release-closure`	Cruzamento com governança real

Todas exigem `Authorization: Bearer <token>` de um usuário `DEVELOPMENT` (ex.: `super_admin`).

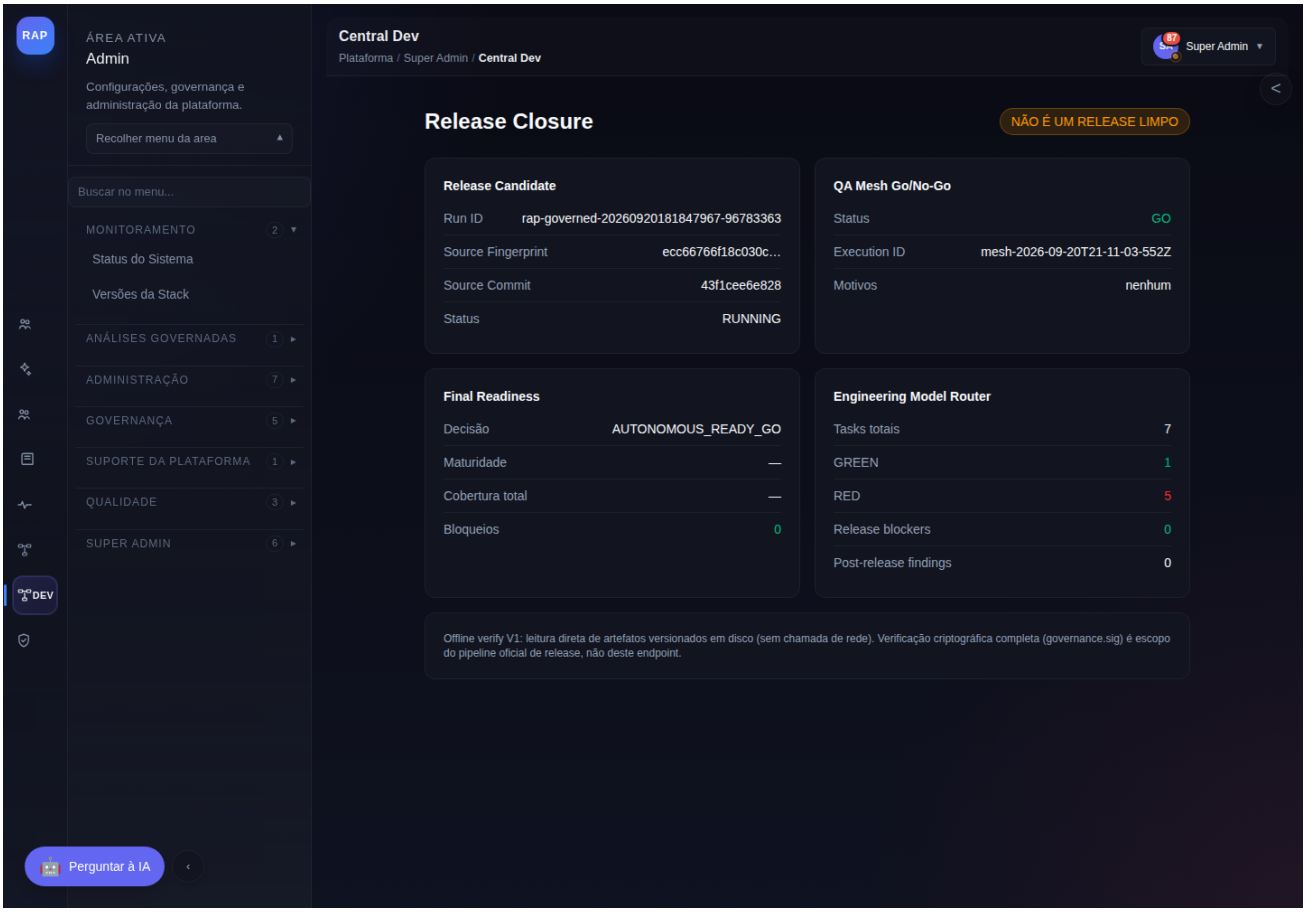


Figure 10: Release Closure: dados reais, “NÃO É UM RELEASE LIMPO” porque há RED pendente